Lean で正規表現エンジンをつくる

そして正しさを証明する

井山梃子歴史館 (pandaman64)

2025-06-15

発表の目的

- 内容
 - ▶ Lean とは?
 - ▶ なぜ Lean で定理を証明するのか?
 - ▶ プログラムの正しさを証明するとは?
- ・仲間を探しに来た
 - ▶ みんなも定理証明、やろう!
 - ▶ (あわよくば) <u>lean-regex</u> にコントリビュート、しよう!

Lean とは?

Leanとは何か

- Lean の二面性
 - ▶ 純粋関数プログラミング言語
 - 依存型:型の中に値が含められる
 - モナドを使った手続き型プログラミング
 - 自由なマクロシステム
 - <u>正規表現、HTML、SQL</u>
 - · 定理証明支援系
 - 数学の定理やプログラムの性質、それらの証明を記述する言語
 - Lean のカーネルが証明が成立することを厳密にチェックする

|Lean のコード例|

```
def fib (n : Nat) : Nat :=
                                       theorem reverse reverse (xs : List \alpha) :
 match n with
                                         xs.reverse.reverse = xs := by
  0 1 1 => 1
                                         induction xs with
  \mid n + 2 \Rightarrow fib + n + fib + (n + 1) \qquad \mid nil \Rightarrow rfl
def main : IO Unit := do
                                         | cons x xs ih =>
  IO.println s!"fib 10 = {fib 10}"
                                           simp [ih]
            プログラムの例
                                                        証明の例
      def sumAt {n} (xs ys : Vector Nat n) (i : Nat) : Option Nat :=
        -- `h` is a proof that `i < n` holds
        if h : i < n then
          some (xs[i]'h + ys[i]'h)
        else
          none
                             証明を使うプログラムの例
```

Lean で正規表現を実装する

- ・ <u>lean-regex</u>: 自作の正規表現ライブラリ
 - ▶ 正規表現をオートマトンにコンパイルして実行
 - ▶ Lean 上で実装の正しいことを検証済み
- ・「実装が正しい」とは?
 - ▶ 正規表現のマッチ結果を厳密に定義する
 - inductive Captures : Iterator → Iterator → CaptureGroups → Expr → Prop
 - ▶ 検索関数 def Regex.find : Iterator → Regex → Option CaptureGroups について
 - **☑** <u>健全性</u>: 見つかったマッチは Captures を必ず満たす
 - ✓ 完全性: Captures を満たすマッチが存在するなら必ずマッチを見つける
 - これらを示す Lean の証明を書いた

なぜ正規表現?

- 1. 正規表現は広く使われている
 - テキスト処理の場面でよく出てくる
 - 実用的なプログラミング言語には正規表現実装がつきもの
- 2. 仕様・実装がほどよく複雑
 - ・ 検索関数の正しさを数学的に明確に定式化できる(けど、細部は微妙)
 - ・実装はオートマトンへのコンパイルや探索など、そこそこ複雑
 - ・エッジケースも含めて定理証明支援系で厳密に表現・検証する価値あり
- 3. パフォーマンスが重要
 - ・大量のテキストを効率よく処理したい
 - ・ Lean の最適化の出番!

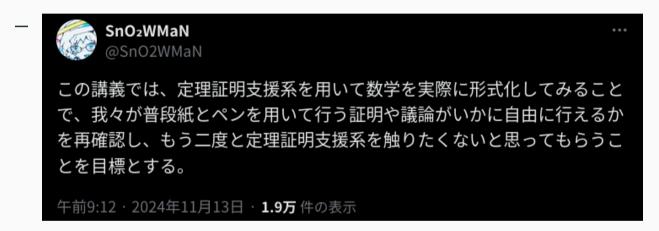
Lean の最適化

- ・2つの実行モデル
 - 1. カーネルによるインタプリタ: 証明の検証・エディタでの実行など
 - 2. C へのコンパイル: Lean を C 言語に変換してネイティブコードを生成
- Cへのコンパイル時はオブジェクトを参照カウンタで保持
 - ▶ 正格な純粋関数型言語なので(基本的には)参照サイクルが発生しない
- 参照カウンタを見るとデータ構造の更新を破壊的変更に最適化できる
 - ▶ 例: let xs' := Array.set xs i v のような操作が実質 O(1)で実行
 - 証明の検証時は xs と xs'の両方が同時に存在するかのように扱える
 - オートマトンベースの正規表現エンジンに最適

なぜ定理証明するのか?

なぜ定理証明するのか?

- ・定理証明は苦しい…
 - ▶ 証明のコード量は実装の 2~20 倍
 - ▶ 定理証明支援系のご機嫌取りでボイラープレートが増える

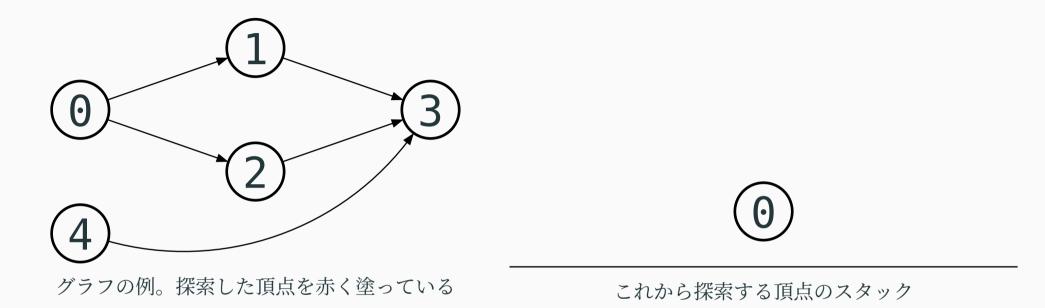


- それでもなぜやるのか?
 - ▶ 信頼性の保証: 暗号処理など、信頼性が要求される領域で確実な保証を得る
 - ▶ 実装の品質向上: 証明過程でバグを発見
 - ▶ パズル的な面白さ: 証明が通った瞬間の達成感は中毒性がある
 - ▶ 深い理解が得られる: これが最も重要!

定理証明で得られる「深い理解」とは

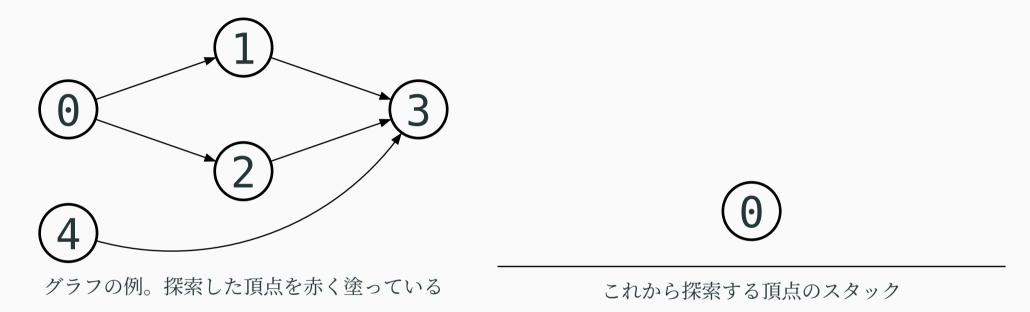
- ・ 証明を書くには**なぜ定理が成立するか**を理解しなければならない
 - ▶ 書いたプログラムがなぜ正しく動くのか?を深く理解する必要がある
- ・プログラムはなぜ正しく動くのか?=よい不変条件が成立しているから
 - ▶ 不変条件: プログラムの各ステップ前後で常に成立している性質
 - プログラムの性質を証明するには
 - 1. 不変条件を見つける
 - 2. 各処理が見つけた不変条件を保存することを示す
 - 3. 見つけた不変条件が所望の性質を導くことを示す
 - どうやって不変条件を見つけるの?
 - 頑張る
 - 具体例を計算したり欲しい性質から逆算したりする

例: DFS で到達可能性を計算する



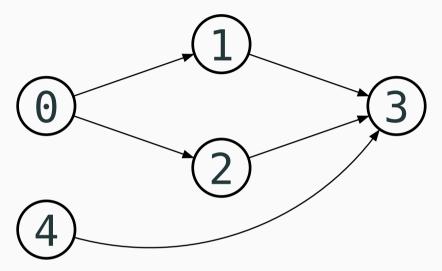
- ・グラフの到達可能性: 頂点 0 から到達できる頂点の集合は?
 - ▶ 正規表現のマッチ ≒ 正規表現をコンパイルしたオートマトンの到達可能性
- ・ DFS (深さ優先探索)で到達可能性の判定ができる。なぜ?
 - ▶ DFS がよい不変条件を満たすから

DFS の不変条件



・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上





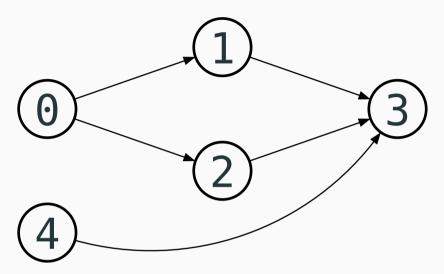
0

グラフの例。探索した頂点を赤く塗っている

これから探索する頂点のスタック

- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する





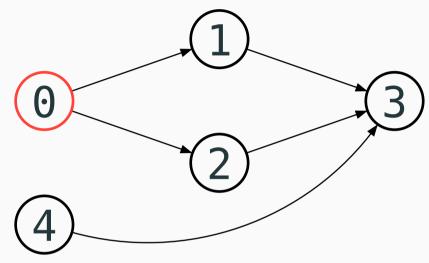


グラフの例。探索した頂点を赤く塗っている

これから探索する頂点のスタック

- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する



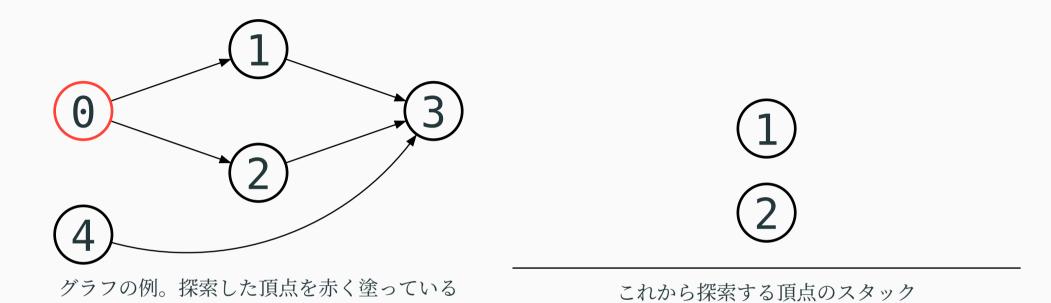


グラフの例。探索した頂点を赤く塗っている

これから探索する頂点のスタック

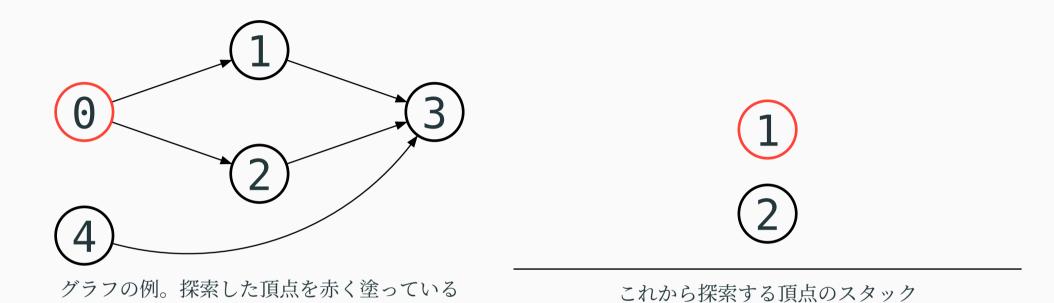
- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する





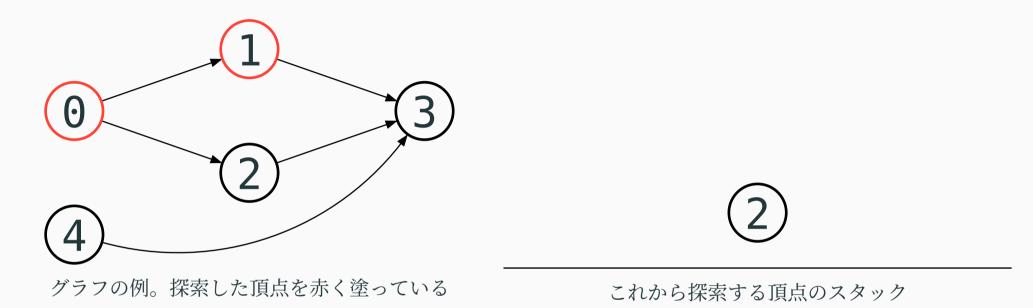
- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する





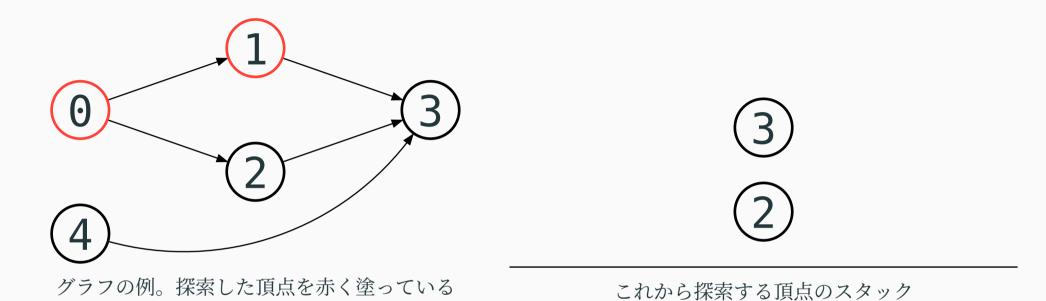
- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する



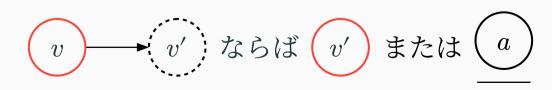


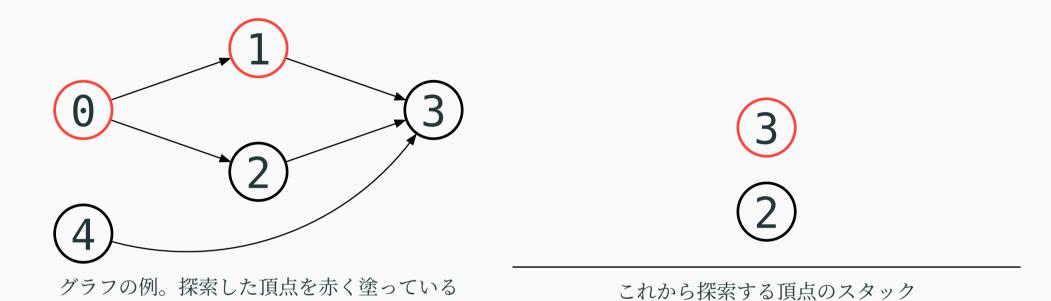
- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する





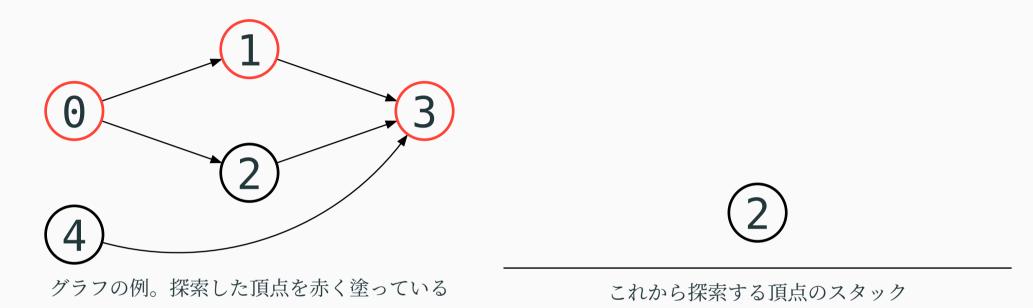
- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する





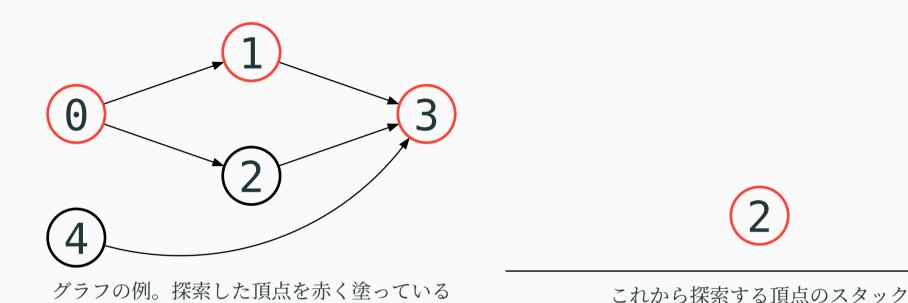
- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する



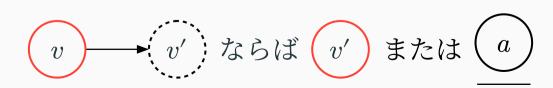


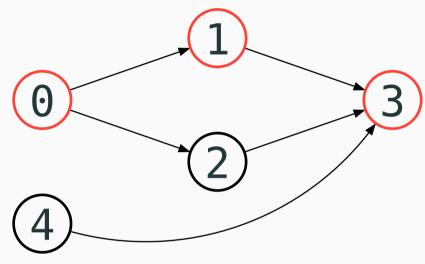
- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する





- ・ **不変条件**: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する



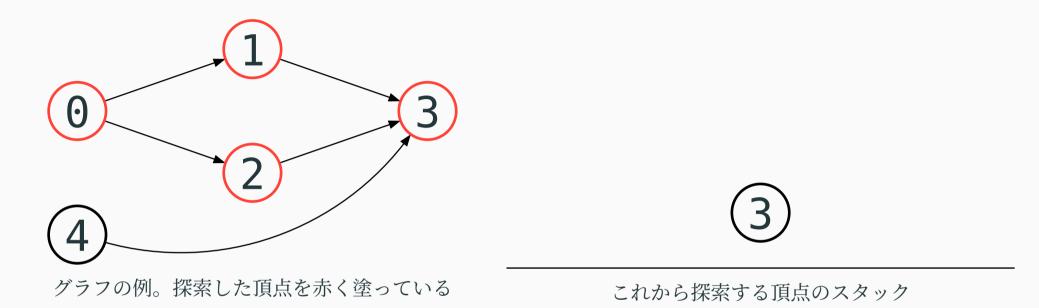


グラフの例。探索した頂点を赤く塗っている

これから探索する頂点のスタック

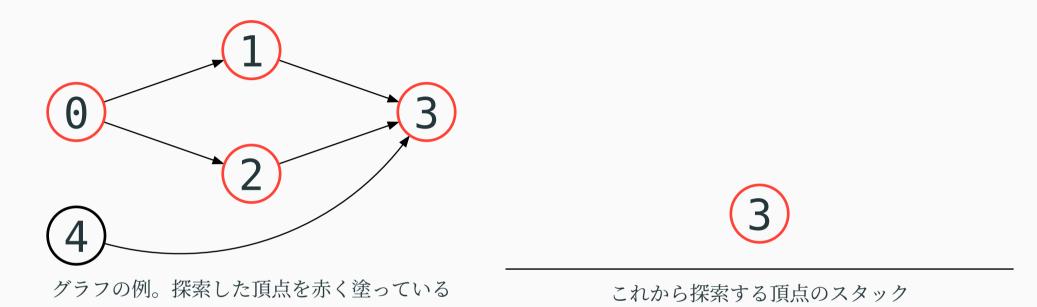
- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する



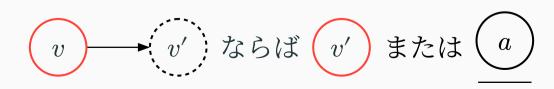


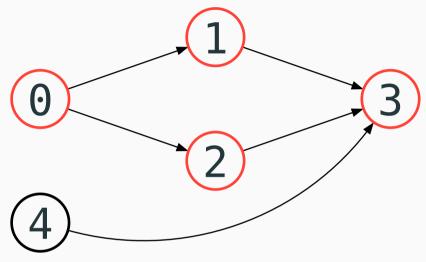
- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する





- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する



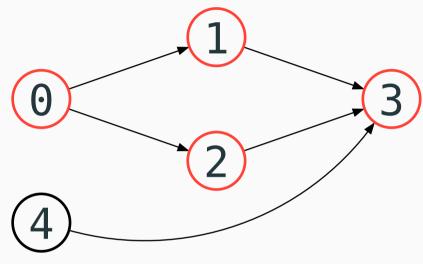


グラフの例。探索した頂点を赤く塗っている

これから探索する頂点のスタック

- ・ 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上
 - ▶ DFS の各ステップが不変条件を保存する



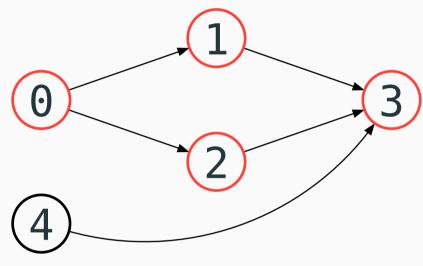


グラフの例。探索した頂点を赤く塗っている

これから探索する頂点のスタック

- スタックが空になったら計算が完了
- 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上



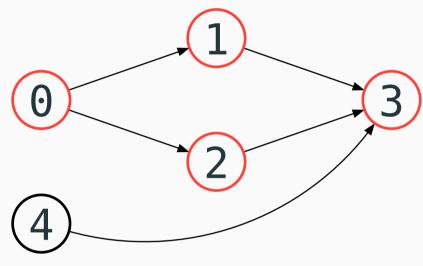


グラフの例。探索した頂点を赤く塗っている

これから探索する頂点のスタック

- スタックが空になったら計算が完了
- 不変条件: 探索済みの頂点から1ステップ先の頂点は既に探索済み or スタック上



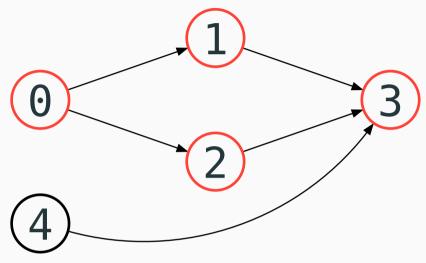


グラフの例。探索した頂点を赤く塗っている

これから探索する頂点のスタック

- スタックが空になったら計算が完了
- ・ 不変条件: 探索済みの頂点から N ステップ先の頂点は既に探索済み or スタック上





グラフの例。探索した頂点を赤く塗っている

これから探索する頂点のスタック

- **不変条件**: 探索済みの頂点から N ステップ先の頂点は既に探索済み
 - ▶ つまり、始点から到達可能な頂点は探索済み
- ・ 逆に、別の不変条件を使うと到達可能な頂点だけ探索することが分かる
- ・したがって、到達可能性を計算するには DFS でグラフを探索すればよい 🎉
 - ▶ よい不変条件が DFS の正しさを導いた

なぜ定理証明するのか?のまとめ

- ・定理証明はたいへん苦しい
- ・定理証明は定理の深い理解をもたらす
 - プログラムの深い理解 = よい不変条件を見つけること
- ・定理証明はとてもやりがいがある
 - ▶ 全てが繋がった瞬間の気持ちよさはとんでもない

証明をエンジニアリングする

証明をエンジニアリングする

- ・定理証明の苦しみを軽減する
 - ▶ 問題を分割することで一度に扱う複雑さを低減する
 - コードを再利用してボイラープレートを減らす
 - 定理証明パターンがありそう
 - 例: ProofData で中間的な定義や証明を整理する
- ・ソフトウェア開発と同じ!!
- Lean 特有の苦しみ
 - ► do 構文は糖衣構文
 - 証明時は脱糖後の式について証明を書くことになる
 - ▶ 依存型は用法用量にお気をつけて

依存型は諸刃の剣

- ・ 依存型: 型の中に値を含められる
 - ▶ let i : Fin 5 のとき、i は 5 未満の自然数
- ・ メリット:
 - ▶ 型の表現力が上がる
 - ▶ パフォーマンス向上
 - def Array.get : (xs : Array α) → Fin xs.size : α は境界チェックしない
- ・ デメリット:
 - ▶ 型チェックが複雑になる(値の等しさもチェックしないといけないため)
 - 明示的なキャストが必要な場合はコードが冗長になる
 - -((x : Fin (n + 1)).cast (...n + 1 = 1 + nの証明...)) : Fin (1 + n)
 - ▶ 実質的に「等しい」値でも型システム的に等しくならないことがある
 - 例: $(3 : Fin 5) \neq (3 : Fin 10)$

依存型の利用戦略

- 使うのは控えめに
 - ▶ ② 型に登場する値が変わらないとき(キャストが必要無いとき)
 - ▶ 🕑 パフォーマンスが重要なとき
 - ▶

 型型に登場する値が変わるとき (キャストが必要なとき)
- 値と一緒に命題を渡すほうが問題が起きないがち
 - ▶ ? def Array.get : (xs : Array α) → (i : Fin xs.size) : α
 - ▶ $\stackrel{}{\models}$ def Array.get : (xs : Array α) → (i : Nat) → (lt : i < xs.size) : α
 - ▶ i が単なる自然数なのでキャストの問題が起きない

まとめ

- · Lean は定理証明支援系であり純粋関数プログラミング言語でもある
 - ▶ Lean で記述したプログラムの性質を Lean 内で証明できる
- Lean で正規表現ライブラリ lean-regex を作っている
 - ▶ しかも、lean-regex の正しさを Lean で検証した
- ・定理証明には対象のプログラムの深い理解が必要
 - ▶ 定理証明は苦しいが、とってもやりがいがある
- みんなも定理証明、やろう!

定理証明がやりたくなったら

- ・ <u>Natural Numbers Game</u>: Lean の楽しいチュートリアル
- <u>Functional Programming in Lean</u>: Lean でのプログラムの書き方と検証
- ・ <u>Mathematics in Lean</u>: Lean で数学を表現する方法 (Mathlib の紹介)

みんなも定理証明、やろう!

<u>lean-regex</u> はいつでもコントリビュータ募集中!